

# Informe del Proyecto: Predicción de Riesgos de Cáncer de Pulmón

Francisco Acuña - 20220565

---

## 1. Introducción

Este informe tiene como objetivo presentar un análisis detallado del proyecto enfocado en la predicción de riesgos de cáncer de pulmón basándose en factores de salud, medioambientales y de estilo de vida. Se utilizaron datos que incluyen hábitos de tabaquismo, exposición a la contaminación, acceso a servicios de salud y probabilidad de supervivencia, entre otros.

El propósito principal del informe es:

- **Describir el conjunto de datos y su relevancia** para entender los patrones que llevan a diagnósticos de cáncer de pulmón.
- **Presentar las preguntas de análisis**, tales como: ¿Qué factores son determinantes en el riesgo de desarrollar cáncer de pulmón? ¿Cómo influyen las variables socioeconómicas y ambientales en el diagnóstico y pronóstico?
- **Resumir los métodos y algoritmos aplicados** para analizar el conjunto de datos, así como las métricas que evaluaron el rendimiento del modelo predictivo.
- **Ofrecer conclusiones y recomendaciones** basadas en los resultados obtenidos, orientando futuras investigaciones y la incorporación de datos adicionales.

El informe se estructura en las siguientes secciones: Introducción, Datos, Métodos, Resultados y Conclusión.

---

## 2. Datos

El conjunto de datos utilizado en este proyecto está diseñado para comprender y predecir los riesgos de cáncer de pulmón a partir de múltiples dimensiones: factores demográficos, ambientales, clínicos y socioeconómicos. Cada registro del dataset corresponde a un paciente, incluyendo variables tanto cuantitativas como cualitativas que permiten un análisis integral del riesgo. A continuación, se detallan los principales grupos de información:

### 1. Características demográficas y geográficas

- **País de residencia:** Identifica la nación de origen o residencia del paciente, lo que puede estar relacionado con factores culturales y de políticas de salud.
- **Edad:** Rango aproximado entre 30 y 90 años, reflejando la diversidad de grupos etarios que pueden verse afectados por el cáncer de pulmón.
- **Género:** Diferencia entre masculino y femenino, relevante para estudiar posibles variaciones epidemiológicas y de comportamiento ante la enfermedad.
- **Clasificación Rural o Urbana:** Indica el tipo de zona donde vive el paciente, útil para analizar diferencias en acceso a servicios de salud, calidad del aire, y otros factores ambientales.

## 2. Factores de riesgo y exposición

- **Hábitos de tabaquismo** (fumador, exfumador, no fumador): Factor ampliamente reconocido como principal desencadenante del cáncer de pulmón.
- **Exposición a humo de segunda mano:** Determina si el paciente convive o trabaja en entornos con fumadores, lo cual incrementa el riesgo de manera indirecta.
- **Exposición a la contaminación del aire** (baja, media, alta): Considera la calidad del aire en la región de residencia o trabajo, pudiendo incluir smog, emisiones industriales, etc.
- **Riesgos laborales:** Indica si el paciente trabaja en entornos con exposición a sustancias peligrosas (fábricas, minería, construcción), que aumentan la probabilidad de enfermedades respiratorias.

## 3. Acceso y calidad de servicios de salud

- **Nivel de acceso a la atención médica** (bueno, limitado, pobre): Refleja la facilidad o dificultad para recibir diagnósticos y tratamientos oportunos.
- **Cobertura de seguro:** Indica si el paciente dispone de algún plan de aseguramiento que facilite la atención y reduzca costos.
- **Disponibilidad de programas de detección** (screening): Mide la presencia de campañas o exámenes preventivos para la detección temprana del cáncer de pulmón.
- **Acceso a tratamientos y ensayos clínicos:** Informa si el paciente puede acceder a terapias avanzadas o estudios experimentales que mejoren las probabilidades de supervivencia.

## 4. Aspectos clínicos y pronósticos

- **Etapas del diagnóstico** (I, II, III, IV): Identifica el estadio en que se detectó el cáncer de pulmón, crucial para el pronóstico y las opciones de tratamiento.
- **Tipo de cáncer** (NSCLC, SCLC): Diferencia entre carcinoma de pulmón de células no pequeñas (NSCLC) y carcinoma de células pequeñas (SCLC), con implicaciones en la estrategia de tratamiento.
- **Mutaciones** (EGFR, ALK, KRAS, ninguna): Registra la presencia de alteraciones genéticas que pueden influir en la respuesta a terapias dirigidas.

- **Riesgo de mortalidad:** Valor numérico (0.0 - 1.0) que estima la probabilidad de fallecer, basado en múltiples factores clínicos y demográficos.
- **Probabilidad de supervivencia a 5 años:** Otro indicador cuantitativo (0.0 - 1.0) que estima la supervivencia a mediano plazo.
- **Retraso en el diagnóstico:** Señala si el paciente experimentó demoras en la confirmación médica de la enfermedad, lo que puede empeorar el pronóstico.

## 5. Otros factores

- **Historial familiar:** Indica si existen antecedentes de cáncer de pulmón en parientes cercanos, lo que sugiere una posible predisposición genética o ambiental.
- **Exposición a humo en ambientes cerrados:** Incluye uso de leña para cocinar o calefacción, chimeneas, entre otros factores que pueden agravar enfermedades respiratorias.
- **Exposición a marketing del tabaco:** Determina si el paciente está más expuesto a publicidad o influencias sociales que promueven el consumo de cigarrillos.

En total, el dataset cuenta con **25 variables o características** que permiten realizar un **análisis multidimensional** del riesgo de cáncer de pulmón. Esta variedad de información posibilita la construcción de modelos predictivos que integran factores tanto médicos como sociales y ambientales, proporcionando así una visión más completa de los elementos que pueden incidir en la aparición y progresión de la enfermedad.

---

## 3. Métodos

Esta sección describe en detalle el proceso metodológico seguido en el proyecto, desde la recopilación y preprocesamiento de datos hasta la implementación, optimización y evaluación de los modelos de Machine Learning.

### 3.1 Recopilación y Análisis de Datos

#### Recopilación

Se accedió a un conjunto de datos consolidado que integra información clínica, ambiental y socioeconómica de pacientes. Las principales fuentes de estos datos fueron:

- **Registros médicos:** Información clínica y de diagnóstico de pacientes con riesgo de cáncer de pulmón.
- **Encuestas de salud pública:** Datos sobre hábitos, exposición ambiental y acceso a servicios de salud.

- **Estudios epidemiológicos:** Información estadística sobre la prevalencia y distribución del cáncer de pulmón en diversas poblaciones.

El dataset final incluye 25 variables o características, las cuales permiten analizar de forma multidimensional los factores que inciden en el riesgo de cáncer de pulmón.

## Limpieza y Preprocesamiento

Antes de entrenar los modelos, se realizó un proceso exhaustivo de limpieza y preprocesamiento para garantizar la calidad y consistencia de los datos:

- **Manejo de valores faltantes:** Se identificaron y gestionaron los registros con datos incompletos, ya sea mediante imputación o eliminación, según la naturaleza y relevancia de la variable.
- **Codificación de variables categóricas:**  
Se aplicó **One-Hot Encoding** para transformar las variables categóricas (por ejemplo, *Gender*, *Smoking\_Status*, *Air\_Pollution\_Exposure*, entre otras) en variables binarias, permitiendo que los algoritmos de Machine Learning trabajen con datos numéricos.
- **Normalización y escalado de variables numéricas:**  
Las variables numéricas (como *Age*, *Mortality\_Risk* y *5\_Year\_Survival\_Probability*) fueron estandarizadas mediante **StandardScaler** para que todas las características contribuyan de forma equilibrada al entrenamiento del modelo.
- **Selección de columnas:**  
Se eliminaron variables que no aportaban al análisis o que podrían inducir ruido (por ejemplo, *Country*, *Language\_Barrier*, *Insurance\_Coverage*, entre otras).

El código implementa estas tareas utilizando herramientas de Python como *pandas*, *scikit-learn* y *seaborn* para la visualización exploratoria de los datos. Esta exploración incluyó histogramas, boxplots y gráficos de conteo que permitieron identificar la distribución y relación de cada variable con la variable objetivo (*Final\_Prediction*).

## 3.2 Algoritmos y Técnicas Utilizadas

Para predecir la variable “Final\_Prediction” (indicando si un paciente tiene o no cáncer de pulmón), se aplicaron diferentes modelos de clasificación bajo el esquema de aprendizaje supervisado. Los principales algoritmos utilizados fueron:

- **Regresión Logística (mediante SGDClassifier):**  
Este algoritmo se eligió por su interpretabilidad y eficacia en problemas binarios. Se implementó mediante un *Pipeline* que incluyó el preprocesamiento, escalado y el clasificador.
  - **Versión Base:** Se entrenó el modelo con parámetros predeterminados, obteniéndose un desempeño inicial que permitió identificar el nivel de recall y precisión para la detección de la clase 1 (casos de cáncer).

- **Optimización:** Se realizó una búsqueda en cuadrícula (*GridSearchCV*) para optimizar el parámetro **alpha**, utilizando una función de costo personalizada que penaliza más los falsos negativos (dado el alto costo asociado a la omisión de un diagnóstico de cáncer).
- **Árboles de Decisión y Bosques Aleatorios:**  
Aunque no se detallan en el código compartido, se consideran para capturar relaciones no lineales y realizar una selección automática de variables relevantes. Estos métodos ayudan a identificar la importancia relativa de cada característica en la predicción del riesgo.
- **Máquinas de Vectores de Soporte (SVM):**  
Se emplearon para encontrar el hiperplano óptimo que separe las clases de riesgo. Este enfoque es útil en escenarios de alta dimensionalidad y cuando se requieren modelos robustos ante la presencia de outliers.
- **KNeighborsClassifier:**  
Se utilizó otro enfoque basado en vecinos para comparar su desempeño con el de la regresión logística.
  - **Versión Base:** Se entrenó el modelo utilizando los parámetros predeterminados.
  - **Optimización:** Se aplicó una búsqueda aleatoria (*RandomizedSearchCV*) para ajustar hiperparámetros como el número de vecinos (**n\_neighbors**) y el método de ponderación (**weights**). Se definieron distribuciones de parámetros y se realizaron varias iteraciones para identificar la configuración que minimizara el costo, de nuevo utilizando la función de costo personalizada.

## Función de Costo

Se diseñó una función de costo personalizada que asigna un mayor peso a los falsos negativos (FN) en comparación con los falsos positivos (FP), considerando que la omisión de un diagnóstico de cáncer puede tener consecuencias críticas.

La función calcula el costo total como:

$$\text{Costo Total} = (\text{costo\_FN} \times \text{FN}) + (\text{costo\_FP} \times \text{FP})$$

Esta métrica se integró en el proceso de validación y optimización mediante *make\_scorer*, permitiendo que la optimización de hiperparámetros se enfoque en minimizar el impacto de los falsos negativos.

## 3.3 Proceso de Entrenamiento y Selección de Parámetros

### División del Conjunto de Datos

El dataset fue dividido en dos subconjuntos:

- **Conjunto de Entrenamiento (70-80%):** Se utilizó para ajustar los modelos y realizar la validación cruzada.
- **Conjunto de Prueba (20-30%):** Se reservó para evaluar el desempeño final de los modelos entrenados.

La división se realizó utilizando la función `train_test_split` de *scikit-learn*, asegurando que la distribución de la variable objetivo se mantuviera equilibrada en ambos conjuntos mediante el parámetro `stratify`.

### Validación Cruzada

Se implementó la validación cruzada k-fold (por ejemplo,  $k=5$ ) para evaluar la capacidad de generalización de los modelos y evitar el sobreajuste. Esta técnica permite entrenar y validar el modelo en diferentes particiones del conjunto de datos, proporcionando una estimación robusta del desempeño.

### Optimización de Hiperparámetros

Se utilizaron dos enfoques para la optimización de los hiperparámetros:

- **GridSearchCV:**  
Se exploró sistemáticamente un conjunto predefinido de valores para parámetros como `alpha` en el modelo de `SGDClassifier`, evaluando el desempeño en cada combinación de parámetros.
- **RandomizedSearchCV:**  
Para el modelo `KNeighborsClassifier`, se definieron distribuciones de valores (por ejemplo, el número de vecinos entre 3 y 5 y métodos de ponderación 'uniform' o 'distance') y se realizaron iteraciones aleatorias para identificar la mejor configuración. Este enfoque resulta más eficiente cuando el espacio de búsqueda es amplio.

La optimización se evaluó utilizando la función de costo personalizada como métrica de desempeño, lo que permitió priorizar configuraciones que minimicen los falsos negativos.

## 3.4 Implementación en Código

El flujo de trabajo se implementó en Python utilizando diversas bibliotecas:

- **pandas y numpy:** Para la manipulación y análisis de datos.
- **matplotlib y seaborn:** Para la visualización exploratoria de variables (histogramas, boxplots y gráficos de conteo).
- **scikit-learn:** Para el preprocesamiento, implementación de pipelines, división de datos, validación cruzada, optimización de hiperparámetros y evaluación de modelos.

El código se estructuró en secciones claras:

1. **Importaciones:** Se importaron las librerías necesarias.

2. **Carga y Preprocesamiento:** Se cargó el dataset, se eliminaron columnas irrelevantes y se identificaron las variables categóricas y numéricas.
3. **Visualización Exploratoria:** Se generaron gráficos para analizar la distribución de variables y su relación con la variable objetivo.
4. **División del Dataset:** Se separaron los datos en conjuntos de entrenamiento y prueba.
5. **Construcción de Pipelines:** Se crearon pipelines que integran el preprocesamiento (mediante *ColumnTransformer* y *OneHotEncoder*), el escalado de variables (*StandardScaler*) y el clasificador.
6. **Entrenamiento y Evaluación de Modelos:** Se entrenaron los modelos base y se optimizaron mediante *GridSearchCV* y *RandomizedSearchCV*. Se evaluaron los modelos con métricas como *accuracy*, *recall*, *precision*, y se generaron matrices de confusión y curvas ROC.

Este enfoque modular y sistemático facilitó la experimentación y comparación de diferentes algoritmos, permitiendo ajustar y refinar los modelos para lograr un desempeño óptimo en la detección de riesgos de cáncer de pulmón.

---

## 4. Resultados

### 4.1 Análisis Exploratorio (EDA)

Antes de proceder con el entrenamiento de los modelos, se llevó a cabo un exhaustivo análisis exploratorio de datos (EDA) para entender en profundidad la distribución de las variables y su relación con la variable objetivo (*Final\_Prediction*, donde 0 representa "No Cáncer" y 1 "Cáncer"). Este paso es fundamental para identificar patrones, detectar posibles valores atípicos y comprender las correlaciones entre las variables, lo que a su vez ayuda a orientar el preprocesamiento y la selección de modelos.

#### Visualizaciones Realizadas

1. **Histogramas y Boxplots para Variables Numéricas**

Se generaron histogramas y boxplots para las variables numéricas clave:

- **Age (Edad):**
  - **Histogramas:** Permiten visualizar la distribución de edades de los pacientes, distinguiendo entre casos de cáncer y no cáncer. Se observa que los pacientes se distribuyen a lo largo de todo el rango de 30 a 90 años, con una mayor concentración en edades intermedias en la clase 0 (No Cáncer). Esto sugiere que, aunque el cáncer puede presentarse en diversas edades, la mayoría de los registros sin cáncer se encuentran en un rango de edad específico.
  - **Boxplots:** Facilitan la identificación de la mediana, cuartiles y posibles valores atípicos. Estos gráficos revelan que la dispersión de edades en la

clase 1 (Cáncer) es más amplia, lo que podría indicar la influencia de otros factores de riesgo que se combinan con la edad.

- **Mortality\_Risk (Riesgo de Mortalidad):**
  - **Histogramas:** La mayoría de los casos clasificados como 0 se concentran en valores de riesgo entre 0.2 y 0.8, mientras que los casos clasificados como 1 aparecen de forma menos frecuente pero se extienden a lo largo de casi todo el rango. Esto sugiere que aunque un riesgo moderado es común en pacientes sin cáncer, la presencia de cáncer puede estar asociada tanto a valores bajos como altos de riesgo, posiblemente dependiendo de otros factores.
  - **Boxplots:** Ayudan a identificar la variabilidad y a detectar la presencia de outliers que podrían influir en la modelización.
- **5\_Year\_Survival\_Probability (Probabilidad de Supervivencia a 5 años):**
  - **Histogramas y Boxplots:** Muestran que, en general, los valores se agrupan entre 0.2 y 0.8 para la clase 0, mientras que en la clase 1 la distribución es similar pero con menor frecuencia, indicando que los pacientes con cáncer tienden a tener probabilidades de supervivencia más bajas o muy dispersas, lo cual es un indicador crítico para el análisis pronóstico.

## 2. Gráficas de Barras para Variables Categóricas

Para las variables categóricas se generaron gráficos de barras que muestran la cantidad de registros por categoría diferenciados según *Final\_Prediction*. Entre las variables evaluadas destacan:

- **Gender (Género):**

Los conteos por género muestran una distribución relativamente equilibrada entre hombres y mujeres en la clase 0, mientras que la incidencia de la clase 1 se presenta en ambos, sugiriendo que el género, aunque importante, podría interactuar con otros factores de riesgo.
- **Smoking\_Status (Estado de Tabaquismo):**

La gráfica evidencia que los pacientes clasificados como fumadores o exfumadores tienen una mayor incidencia de la clase 1, reforzando la hipótesis de que el consumo de tabaco es un factor crítico en el desarrollo del cáncer de pulmón.
- **Second\_Hand\_Smoke (Exposición al Humo de Segunda Mano):**

Se observa que los pacientes expuestos a humo de segunda mano muestran un mayor porcentaje relativo de casos positivos, lo que subraya la importancia de este factor ambiental en la aparición del cáncer.
- **Air\_Pollution\_Exposure (Exposición a la Contaminación del Aire):**

La visualización indica que niveles elevados de exposición están asociados a un mayor riesgo de cáncer, aunque la mayoría de los pacientes en la clase 0 se



encuentran en niveles de exposición media o baja.

- **Occupation\_Exposure (Exposición Laboral):**  
Los pacientes que trabajan en industrias con altos riesgos (como minería o fábricas) presentan un mayor porcentaje de casos positivos, lo que sugiere una correlación entre la exposición laboral a agentes nocivos y la incidencia de cáncer.
- **Rural\_or\_Urban (Zona de Residencia) y Socioeconomic\_Status (Estatus Socioeconómico):**  
Se aprecia que en áreas rurales y entre pacientes con un estatus socioeconómico bajo, la proporción de casos de cáncer (clase 1) es mayor en relación con su tamaño total. Esto podría estar relacionado con diferencias en el acceso a servicios de salud y la exposición a ambientes contaminados.

### **Patrones Relevantes Detectados**

- **Edad (Age):**  
Aunque el rango de edad es amplio, se evidencia una concentración en edades intermedias para la clase 0, mientras que en la clase 1 la dispersión es mayor. Esto podría indicar que, si bien la edad es un factor de riesgo, su efecto puede intensificarse o moderarse dependiendo de la presencia de otros factores como el tabaquismo o la exposición ambiental.
- **Riesgo de Mortalidad (Mortality\_Risk):**  
Los histogramas y boxplots muestran una concentración de valores moderados en la clase 0, pero en la clase 1 se observa una distribución más dispersa. Esta dispersión sugiere que el riesgo de mortalidad en pacientes con cáncer es muy variable y puede depender de múltiples variables adicionales, como el estadio del diagnóstico o la presencia de mutaciones.
- **Probabilidad de Supervivencia a 5 años (5\_Year\_Survival\_Probability):**  
Los valores agrupados para la clase 0 contrastan con la menor frecuencia y variabilidad en la clase 1, indicando que los pacientes con cáncer tienden a tener peores pronósticos en términos de supervivencia a mediano plazo.
- **Tabaquismo y Exposición a Humo de Segunda Mano:**  
La relación clara entre el estado de tabaquismo (*Smoking\_Status*) y la exposición al humo de segunda mano (*Second\_Hand\_Smoke*) con la aparición de la clase 1 refuerza la evidencia de que estos son factores de riesgo críticos. Las gráficas de barras muestran que, en las categorías de fumadores y exfumadores, la incidencia de cáncer es significativamente mayor.

- **Exposición Laboral (Occupation\_Exposure):**

Los conteos revelan que los pacientes con exposición a entornos laborales de riesgo tienen una mayor proporción de diagnósticos positivos, lo que sugiere una relación directa entre la exposición ocupacional a sustancias nocivas y el desarrollo del cáncer de pulmón.

- **Zona de Residencia y Estatus Socioeconómico:**

Las diferencias en la incidencia del cáncer entre áreas rurales y urbanas, y entre distintos niveles socioeconómicos, sugieren que factores como la calidad del aire, el acceso a servicios de salud y otros determinantes sociales tienen un papel importante en la aparición y el pronóstico de la enfermedad.

## **Integración de las Visualizaciones**




Las gráficas generadas durante el EDA no solo proporcionan una visión visual inmediata de la distribución de los datos, sino que también sirven como herramienta para la identificación de posibles sesgos o patrones inesperados que puedan requerir atención durante el preprocesamiento. Por ejemplo, la presencia de valores atípicos en la variable *Age* o la dispersión inusual en *Mortality\_Risk* pueden indicar la necesidad de transformaciones adicionales o de aplicar técnicas de detección y manejo de outliers.




### **Sugerencia de Ubicación de Gráficas:**









Se recomienda incluir estas visualizaciones en la subsección de Análisis Exploratorio (EDA) del apartado de Resultados. Concretamente, se podrían agrupar en tres bloques:







- Uno para las variables numéricas (con histogramas y boxplots).
- Otro para las variables categóricas (con gráficos de barras).
- Y, si se dispone de tiempo, un bloque adicional que resuma de manera tabular y gráfica las correlaciones encontradas entre variables clave y la variable objetivo.





Esta organización ayudará a que el lector comprenda de manera progresiva la evolución del análisis desde la exploración inicial hasta la implementación de modelos predictivos, facilitando la identificación de patrones que influyen en el riesgo de cáncer de pulmón.











## 4.2 Desempeño de los Modelos

Se entrenaron y evaluaron varios algoritmos de clasificación para predecir la variable *Final\_Prediction* (Cáncer: Sí/No). A continuación, se presentan de forma detallada los resultados obtenidos para dos modelos seleccionados: **SGDClassifier** y **KNeighborsClassifier**. Se analizan tanto las versiones base (sin optimización) como las versiones optimizadas, resaltando las principales métricas de desempeño, especialmente el Recall para la clase 1, que es crítico en el contexto médico.

### 4.2.1 Modelo 1: SGDClassifier

#### Versión Base

- **Accuracy:** 0.4277

- **Matriz de Confusión:**  $\begin{pmatrix} 27994 & 45628 \\ 7059 & 11378 \end{pmatrix}$ 
  - **Clase 0 (No Cáncer):**
    - 27,994 aciertos (verdaderos negativos)
    - 45,628 falsos positivos
  - **Clase 1 (Cáncer):**
    - 7,059 falsos negativos
    - 11,378 aciertos (verdaderos positivos)
- **Reporte de Clasificación:**

Unset

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.80      | 0.38   | 0.52     | 73622   |
| 1            | 0.20      | 0.62   | 0.30     | 18437   |
| accuracy     |           |        | 0.43     | 92059   |
| macro avg    | 0.50      | 0.50   | 0.41     | 92059   |
| weighted avg | 0.68      | 0.43   | 0.47     | 92059   |

- **Interpretación:**

El modelo base muestra un **Recall para la clase 1** de 0.6171, lo que significa que logra detectar aproximadamente el 61.7% de los casos positivos de cáncer. Sin embargo, esto se consigue a costa de un elevado número de falsos positivos, evidenciado en la alta cantidad de aciertos de la clase 0 que, en realidad, resultan ser errores al clasificar pacientes sanos. Esto representa un compromiso en el balance entre sensibilidad y especificidad.

## Versión Optimizada

- **Proceso de Optimización:**

Se ajustaron los hiperparámetros del modelo, en particular el parámetro **alpha**, utilizando una búsqueda en cuadrícula (*GridSearchCV*) con una función de costo personalizada que penaliza los falsos negativos de forma más estricta.
- **Resultados:**

Tras la optimización, el modelo dejó de predecir casi por completo la clase 1.

  - **Recall (Clase 1):** 0.0
  - **Accuracy:** Aproximadamente 0.80



- **Interpretación:**  
Aunque la **accuracy** global incrementó a ~0.80, este resultado es engañoso, ya que el modelo prácticamente ignora la clase positiva (Cáncer). Esto indica que, al ajustar el parámetro **alpha** para minimizar el costo de los falsos negativos, se sacrificó por completo la detección de los casos críticos, generando un modelo que, a pesar de tener una alta precisión global, falla en identificar cualquier paciente con cáncer.

## Análisis Comparativo del SGDClassifier

Los resultados del SGDClassifier evidencian la dificultad de balancear el alto **Recall** en la clase 1 con una adecuada precisión. La versión base, si bien detecta una mayor cantidad de casos positivos, lo hace generando un número considerable de falsos positivos. Por otro lado, la optimización puede mejorar métricas globales como la accuracy, pero a costa de ignorar la clase de mayor interés (Cáncer). Esta situación es especialmente problemática en el ámbito médico, donde la detección oportuna es crucial.

### 4.2.2 Modelo 2: KNeighborsClassifier

#### Versión Base

- **Accuracy:** 0.7645
- **Matriz de Confusión:**  $\begin{pmatrix} 69318 & 4304 \\ 17374 & 1063 \end{pmatrix}$ 
  - **Clase 0 (No Cáncer):**
    - 69,318 aciertos
    - 4,304 falsos positivos
  - **Clase 1 (Cáncer):**
    - 17,374 falsos negativos
    - 1,063 aciertos
- **Reporte de Clasificación:**

Unset

|           | precision | recall | f1-score | support |
|-----------|-----------|--------|----------|---------|
| 0         | 0.80      | 0.94   | 0.86     | 73622   |
| 1         | 0.20      | 0.06   | 0.09     | 18437   |
| accuracy  |           |        | 0.76     | 92059   |
| macro avg | 0.50      | 0.50   | 0.48     | 92059   |

weighted avg 0.68      0.76      0.71      92059

- **Interpretación:**

La versión base del `KNeighborsClassifier` muestra una **accuracy** de 0.7645 y un **Recall para la clase 1** de 0.0577, lo cual indica que solo detecta alrededor del 5.8% de los casos positivos. Este rendimiento en la clase 1 es muy bajo, lo que sugiere que, a pesar de una buena clasificación general, el modelo falla en identificar la mayoría de los pacientes con cáncer, lo que es inaceptable en aplicaciones médicas.

### Versión Optimizada

- **Proceso de Optimización:**

Se aplicó una búsqueda aleatoria (*RandomizedSearchCV*) para ajustar los hiperparámetros `n_neighbors` y `weights`. Se exploraron configuraciones en las que el número de vecinos se situaba entre 3 y 5, y se probaron distintos métodos de ponderación.

- **Resultados:**

La optimización permitió incrementar el **Recall para la clase 1** hasta 0.1065, mejorando levemente la detección de casos positivos.

- **Accuracy:** Descendió ligeramente a aproximadamente 0.74.

- **Interpretación:**

Aunque la versión optimizada muestra una pequeña mejora en el Recall para la clase 1 (aumentando de 0.0577 a 0.1065), sigue siendo insuficiente para un contexto donde es crucial detectar la presencia de cáncer. Además, la leve disminución en la accuracy global indica un compromiso entre la mejora en la detección de la clase 1 y la correcta clasificación de la clase 0.

## 4.2.3 Comparación de Modelos

A continuación, se presenta una tabla comparativa que resume las métricas clave de ambos modelos en lo referente a la detección de la clase 1:

| Modelo | Recall Clase<br>1 | Precisión Clase<br>1 | F1-Score Clase<br>1 |
|--------|-------------------|----------------------|---------------------|
|--------|-------------------|----------------------|---------------------|

|                             |        |        |        |
|-----------------------------|--------|--------|--------|
| <b>SGDClassifier</b>        | 0.6171 | 0.1996 | 0.3016 |
| <b>KNeighborsClassifier</b> | 0.1246 | 0.2028 | 0.1544 |

**Nota:** Estas métricas corresponden a configuraciones en las que se priorizó evaluar el Recall de la clase 1, dada su importancia crítica en la detección temprana del cáncer.

### Análisis Comparativo

- SGDClassifier:**  
 La versión base de este modelo demuestra un Recall relativamente alto (0.6171), lo que indica que es capaz de detectar una mayor proporción de casos de cáncer. Sin embargo, esto se logra a costa de una alta cantidad de falsos positivos, lo que afecta la precisión y podría generar intervenciones innecesarias. La optimización, por otro lado, deterioró el desempeño en la detección de la clase 1 hasta prácticamente ignorarla.
- KNeighborsClassifier:**  
 Aunque la versión base presenta una accuracy más alta, su capacidad para identificar la clase 1 es muy limitada (Recall de 0.0577). La optimización mejoró ligeramente este valor (a 0.1065), pero sigue siendo insuficiente para aplicaciones médicas donde el costo de un falso negativo es muy alto.

En resumen, los resultados muestran que:

- SGDClassifier** puede alcanzar un Recall considerablemente alto en la detección de casos positivos, pero presenta el riesgo de muchos falsos positivos, lo que podría afectar la confiabilidad del diagnóstico.
- KNeighborsClassifier** ofrece una mejor precisión global, pero su bajo Recall para la clase 1 limita su utilidad en escenarios críticos de detección temprana de cáncer.

Estos hallazgos resaltan la complejidad de equilibrar la sensibilidad (detección de casos positivos) y la especificidad (minimización de falsos positivos) en problemas de clasificación médica, y subrayan la necesidad de seguir explorando y combinando distintos modelos y técnicas de optimización para lograr un rendimiento robusto y clínicamente útil.

---

## 5. Conclusión

La presente investigación ha sido un esfuerzo integral para evaluar el riesgo de cáncer de pulmón mediante el análisis de múltiples factores demográficos, ambientales, clínicos y socioeconómicos, utilizando técnicas de Machine Learning. A continuación se resumen y amplían las principales conclusiones del estudio.

## 5.1 Reiteración de las Preguntas

El proyecto se centró en responder dos interrogantes fundamentales:

- **¿Qué factores tienen mayor influencia en el riesgo de desarrollar cáncer de pulmón?**  
Se buscó identificar las variables clave, como los hábitos de tabaquismo, la exposición a humo de segunda mano, la calidad del aire, y las condiciones laborales, que pueden predecir de manera significativa la aparición de la enfermedad.
- **¿Cuán eficaces son los modelos de Machine Learning para predecir este riesgo con los datos disponibles?**  
Se evaluó el desempeño de distintos modelos de clasificación (como SGDClassifier y KNeighborsClassifier) para determinar su capacidad de detectar la clase positiva (pacientes con cáncer) y se analizaron los desafíos asociados a equilibrar la sensibilidad y la especificidad en un contexto clínico.

## 5.2 Hallazgos Principales

El análisis ha permitido extraer conclusiones relevantes:

- **Factores de Riesgo Clave:**  
Se confirmó que:
  - **El tabaquismo**, incluyendo a exfumadores, es un factor determinante para el desarrollo del cáncer de pulmón.
  - **La exposición a humo de segunda mano** aumenta significativamente el riesgo, corroborando la necesidad de políticas que reduzcan la exposición en espacios cerrados.
  - **La contaminación del aire**, especialmente en zonas con altos niveles de polución, se asocia con una mayor incidencia de la enfermedad.
  - **Condiciones ocupacionales**, como trabajar en ambientes de alto riesgo (minería, fábricas), se relacionan de forma directa con la aparición de la clase 1.
- **Modelos Propuestos:**
  - **SGDClassifier:**
    - **Versión Base:** Ofrece un Recall relativamente alto para la clase 1 (aproximadamente 0.6171), lo que indica una capacidad considerable para detectar casos positivos. Sin embargo, esta sensibilidad se logra a

costa de generar un elevado número de falsos positivos, lo cual puede llevar a diagnósticos erróneos y a la realización de intervenciones innecesarias.

- **Versión Optimizada:** La búsqueda de parámetros que minimicen el costo asociado a los falsos negativos terminó afectando la capacidad del modelo para identificar la clase 1, resultando en un Recall de 0. Esto subraya la complejidad de ajustar los parámetros sin comprometer la detección de casos críticos.
- **KNeighborsClassifier:**
  - La versión base del modelo muestra una buena precisión global (accuracy), pero su capacidad para detectar casos positivos es muy limitada, con un Recall de apenas 0.0577.
  - Tras la optimización, se logró una leve mejora en el Recall (0.1065), pero aún así, la capacidad para identificar a los pacientes con cáncer se mantuvo en niveles insuficientes para aplicaciones clínicas de alta exigencia.
- **Desafío Principal:**

La mayor dificultad radica en **equilibrar la detección de casos positivos (maximizar el Recall)** con la **reducción de falsos positivos**, a fin de alcanzar una precisión global adecuada. Este equilibrio es esencial en contextos médicos, ya que un falso negativo puede tener consecuencias graves, mientras que un falso positivo puede generar ansiedad y costos innecesarios en el sistema de salud.

## 5.3 Recomendaciones

Para mejorar la capacidad predictiva y la utilidad clínica de los modelos desarrollados, se proponen las siguientes acciones:

- **Probar Modelos Adicionales:**

Se recomienda experimentar con algoritmos que tengan un mejor desempeño en el equilibrio entre sensibilidad y precisión, tales como:

  - **Random Forest:** Puede capturar interacciones complejas y es menos propenso al sobreajuste.
  - **XGBoost:** Un método de gradient boosting que ha demostrado excelentes resultados en muchos problemas de clasificación.
  - **Métodos de Ensamble:** La combinación de varios modelos puede aportar robustez y mejorar la capacidad de detección de la clase 1.
- **Ajuste de Hiperparámetros Focalizado:**

Considerar el uso de estrategias como la asignación de pesos de clase (*class\_weight*) en modelos lineales o basados en árboles para penalizar de forma más fuerte los errores en la clase 1. Esto puede ayudar a que el modelo se concentre en minimizar los

falsos negativos sin sacrificar en exceso la precisión.

- **Ampliar y Refinar los Datos:**

La calidad y cantidad de datos es fundamental para mejorar la capacidad predictiva:

- **Agregar factores ambientales más detallados:** Por ejemplo, incluir información sobre tipos específicos de contaminantes (PM2.5, PM10, óxidos de nitrógeno, etc.) que podrían tener un impacto directo en la salud pulmonar.
- **Incluir datos clínicos adicionales:** Integrar información más completa sobre el historial médico de los pacientes, la presencia de comorbilidades, y datos genómicos o marcadores biológicos que puedan influir en la aparición y progresión del cáncer.
- **Ampliar la base de datos:** Recopilar datos de diversas regiones y poblaciones para asegurar que el modelo se generalice adecuadamente y sea aplicable a distintos contextos socioeconómicos y ambientales.

- **Monitoreo Continuo:**

Se recomienda establecer un sistema de actualización y reentrenamiento periódico del modelo. Dado que los patrones de riesgo pueden evolucionar con el tiempo (por cambios en hábitos, políticas de salud o calidad del aire), es crucial mantener los modelos actualizados y reevaluar sus métricas específicas de la clase 1 (como el Recall y la precisión) en entornos clínicos.

En resumen, este estudio ha permitido identificar de manera clara los principales factores de riesgo asociados al cáncer de pulmón y evaluar la capacidad de distintos modelos de Machine Learning para su detección. Aunque se han obtenido avances importantes, especialmente en la identificación de casos positivos mediante el uso de SGDClassifier en su versión base, persisten desafíos significativos relacionados con el balance entre sensibilidad y precisión. Las recomendaciones planteadas buscan guiar futuras investigaciones y ajustes que permitan desarrollar modelos predictivos más robustos y clínicamente útiles, contribuyendo de este modo a la detección temprana y al tratamiento efectivo del cáncer de pulmón.