



CREATIVE

PREDICCIÓN DE PRECIOS DE VEHÍCULOS USADOS EN EL REINO UNIDO

PROJECT

2025

FRANCISCO ACUÑA



AGENDA

01 | Descripción
del Dataset

02 | Exploración de
los Datos

03 | Preprocesamiento

04 | Comparación de
Modelos

05 | Ajuste de
Hiperparámetros

06 | Resultados
Finales

07 | Conclusiones y
Recomendaciones

DESCRIPCIÓN DEL DATASET


- N° de registros: 75,978 → 69,089 tras limpieza
- Variables: make, model, transmission, fuelType, year, mileage, tax, mpg, engineSize, price
- Se detectaron 6,529 valores faltantes en tax y mpg, que fueron rellenados con la mediana.
- Había 1,319 registros duplicados, los cuales se eliminaron.
- Se detectaron outliers extremos en variables como price y mileage.
- Se eliminaron utilizando el método IQR

Tamaño inicial antes de eliminar outliers: (74659, 10)
Tamaño después de eliminar outliers en 'price': (71949, 10)
Tamaño después de eliminar outliers en 'mileage': (69089, 10)

Primeras 5 filas del dataset:


	model	year	transmission	mileage	fuelType	tax	mpg	engineSize	make	price
0	Polo	2017	Manual	36874	Petrol	20.0	60.1	1.2	vw	10250
1	Fabia	2016	Manual	39386	Petrol	20.0	60.1	1.2	skoda	8250
2	Grandland X	2018	Automatic	8935	Diesel	145.0	57.7	1.5	vauxhall	16299
3	Fiesta	2016	Manual	18606	Petrol	20.0	62.8	1.0	ford	10199
4	Octavia	2015	Manual	26000	Diesel	30.0	61.4	2.0	skoda	12790

Exploración de los Datos



- Las variables numéricas como price y mileage presentan asimetría a la derecha (sesgo positivo), lo que indica la presencia de valores extremos o autos atípicos.
- Esto refuerza la decisión de aplicar tratamiento de outliers.

Exploración de los Datos



- engineSize tiene la mayor correlación con el precio (0.63).
- year también tiene una correlación moderada con price (0.50).
- mileage se relaciona negativamente con price (-0.43), lo cual es esperable.

PREPROCESAMIENTO


- Las columnas tax y mpg presentaban valores nulos.
- Se imputaron usando la mediana, ya que es robusta ante outliers.
- Variables categóricas: make, model, transmission, fuelType
- Se aplicó One-Hot Encoding, eliminando la primera categoría (drop_first=True) para evitar multicolinealidad.
- Entrenamiento: 70%
- Prueba: 30%

Dimensiones conjunto entrenamiento: (48362

Dimensiones conjunto prueba: (20727

MAE promedio en validación cruzada:
Linear Regression: MAE promedio = 1817.53
Ridge Regression: MAE promedio = 1820.65
Decision Tree: MAE promedio = 1431.87
Random Forest: MAE promedio = 1147.51
Gradient Boosting: MAE promedio = 1814.27

Comparación de Modelos




AJUSTE DE HIPERPARÁMETROS

Se aplicó RandomizedSearchCV para encontrar la mejor configuración

MAE promedio en CV para modelos afinados:
Random Forest (afinado): MAE = 1129.62
Decision Tree (afinado): MAE = 1348.62
Gradient Boosting (afinado): MAE = 1101.99

Modelo	Mejores Parámetros
Random Forest	n_estimators=300, max_features='sqrt', min_samples_split=2, max_depth=None
Decision Tree	max_depth=None, min_samples_split=10, min_samples_leaf=1
Gradient Boosting	n_estimators=200, learning_rate=0.1, max_depth=10, min_samples_split=2


AJUSTE DE HIPERPARÁMETROS



Comparación de Modelos


Modelo seleccionado:

- Gradient Boosting Regressor



Métrica	Resultado
MAE (Error absoluto medio)	£1063.97
RMSE (Error cuadrático medio)	£1523.85
R ² Score (Coeficiente de determinación)	0.9549
MAPE (MAE porcentual)	6.93%

Comparación de Modelos



Conclusiones y Recomendaciones

Ventajas del modelo elegido (Gradient Boosting)

- Captura relaciones no lineales complejas entre variables.
- Estable y resistente al sobreajuste si se ajustan los hiperparámetros correctamente.
- Consistentemente mostró mejor desempeño que modelos como Decision Tree y Random Forest.

GRACIAS
