

Predicción de Precios de Vehículos Usados en el Reino Unido

Introducción

El objetivo de este informe es presentar el desarrollo de un modelo de machine learning para predecir el precio de venta de vehículos usados en el Reino Unido. La motivación principal es apoyar a concesionarios, plataformas de venta y compradores en la estimación precisa del valor de un automóvil basándose en sus características. Para ello, se utilizó un dataset con más de 75,000 registros, obtenidos de sitios web del Reino Unido.

Datos


El dataset original contiene 75,978 registros y 10 columnas:

- **Variables categóricas:** make, model, transmission, fuelType
- **Variables numéricas:** year, mileage, tax, mpg, engineSize, price


Algunos puntos clave:



- Se detectaron valores faltantes en tax y mpg (~6,500 casos), que fueron imputados con la mediana.
- Había 1,319 duplicados, los cuales fueron eliminados.
- Se aplicó una limpieza de outliers usando el método IQR sobre variables clave como price, mileage, tax, mpg y engineSize, reduciendo el dataset final a 69,089 registros.
- Se realizó One-Hot Encoding sobre las variables categóricas, lo que generó 169 columnas en total.



Distribución de Variables Numéricas




Distribución de make









Métodos

Análisis y Preprocesamiento

Se exploraron las distribuciones de variables, correlaciones con el precio, y se evaluó visualmente la presencia de outliers. Posteriormente:

- Se imputaron valores nulos con la mediana.
- Se codificaron variables categóricas con One-Hot Encoding.
- Se escalaron variables numéricas con `StandardScaler`.
- Se separaron los datos en conjunto de entrenamiento (70%) y prueba (30%).

Algoritmos evaluados

Se probaron seis modelos utilizando validación cruzada con MAE como métrica:

- Linear Regression
- Ridge Regression
- Decision Tree Regressor
- Random Forest Regressor
- Gradient Boosting Regressor

Selección y ajuste de hiperparámetros

Tras la comparación inicial, se seleccionaron los tres modelos con mejor desempeño para afinarlos usando RandomizedSearchCV:


- **Random Forest (MAE = 1129.62)**
- **Decision Tree (MAE = 1348.62)**
- **Gradient Boosting (MAE = 1101.99)**


Gradient Boosting fue seleccionado como modelo final por ser el más preciso tras la optimización.

Resultados

El modelo final, Gradient Boosting Regressor con hiperparámetros afinados, se entrenó con el conjunto de entrenamiento y se evaluó con el conjunto de prueba. Los resultados fueron:

- **MAE (Error Absoluto Medio):** £1,063.97
- **RMSE (Raíz del Error Cuadrático Medio):** £1,523.85
- **R² Score:** 0.9549
- **MAE porcentual (MAPE):** 6.93 %





El modelo logra predecir los precios con una precisión promedio del 93.36%, lo que representa un muy buen rendimiento para datos del mundo real.

Las gráficas de dispersión entre los precios reales y predichos, y la distribución de los errores, confirman que la mayor parte de las predicciones están muy cerca del valor real.

Conclusión

Se comenzó con la pregunta: “¿Podemos predecir con precisión el precio de un auto usado en el Reino Unido usando machine learning?” La respuesta es sí. El modelo de Gradient Boosting logró un MAE de £1101 y un R^2 de 0.95, mostrando una gran capacidad predictiva.

Conclusiones clave:

- El preprocesamiento cuidadoso (limpieza, codificación, escalado) fue clave para el rendimiento.
- Los modelos basados en árboles tuvieron mejor desempeño que los lineales.
- El ajuste de hiper parámetros mejoró significativamente la precisión.